Factorii socio-economici ai ocupării forței de muncă la nivel regional NUTS 2 în Uniunea Europeană

Galoș Ioana

Academia de Studii Economice din București, Facultatea de Cibernetică, Statistică și Informatică Economică

Rezumat. În această lucrare am analizat ce influențează rata ocupării în regiunile NUTS 2 din UE, cu accent pe șomajul în funcție de nivelul de educație și pe ponderea tinerilor NEET. Am lucrat cu date Eurostat și am făcut analiza spațială în GeoDa. Ocuparea nu e distribuită la întâmplare: indicele Moran's I global ($I = 0{,}172$, $p < 0{,}05$) arată o autocorelație spațială pozitivă, iar LISA scoate în evidență clustere High-High în nord-vestul Europei și Low-Low în sud și est. Modelul ales, Spatial Lag (AIC = 1523,51, $\rho = 0{,}821$), arată că șomajul educațional ($\beta = -0{,}795$) și ponderea tinerilor NEET ($\beta = -1{,}088$) reduc semnificativ ocuparea. Efectul nu rămâne în interiorul regiunii, ci se transmite și vecinilor ei.

1. Introducere și prezentarea datelor

Scopul analizei este să identific factorii socio-economici care influențează rata ocupării la nivel regional (NUTS 2) în UE. Am pornit de la ipoteza că structura educațională a șomajului și excluderea tinerilor de pe piața muncii scad ocuparea, iar acest efect are și o componentă spațială. Altfel spus, regiunile nu sunt unități independente, ci sunt legate între ele prin efecte de vecinătate (Anselin, 1988; LeSage și Pace, 2009).

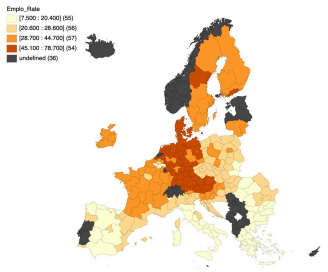
Ocuparea e unul dintre indicatorii centrali ai coeziunii economice și sociale în Europa. Diferențele dintre regiuni nu apar întâmplător. Ele reflectă structuri istorice, educaționale și demografice care se repetă în spațiu (Elhorst, 2014). Șomajul educațional și ponderea tinerilor NEET au o distribuție geografică clară, de aceea am considerat că merită analizate și din perspectivă spațială, nu doar ca simple medii naționale.

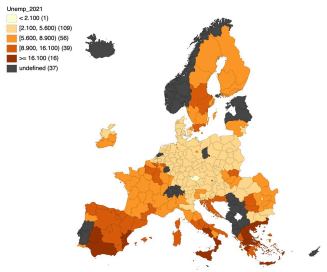
	Variabilă	Definiție	U.M.	Sursă Eurostat
Y	Emplo_Rate	Rata ocupării	%	lfst_r_lfe2emprt
X1	Unemp_2021	Rata șomajului după nivelul de educație	%	edat_lfse_04
X2	NEET_Youth	Tineri NEET (15–29 ani)	%	edat_lfse_20

Tabelul 1. Variabilele utilizate

2. Analiza exploratorie spațială

Am făcut câte o hartă coropletă pentru fiecare variabilă și am ales tipul hărții după distribuția datelor. Pentru rata ocupării, care e puternic asimetrică, am folosit cuantile. Pentru șomajul educațional am ales natural breaks, pentru că datele formează grupuri clare. Pentru tinerii NEET am folosit abaterea standard, ca să se vadă ce regiuni se abat mult de la medie.





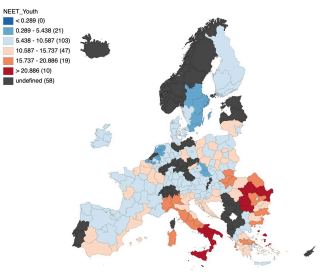


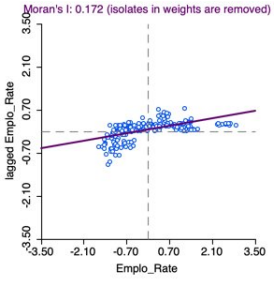
Fig. 1. Rata ocupării (cuantile) Fig. 2. Șomajul educațional (natural breaks) Fig. 3. Tineri NEET (abatere standard)

Diferența dintre Nord-Vest și Sud-Est se vede încă de pe hărți. Olanda, Germania și Danemarca ocupă aproape toată cuantila superioară a ocupării (45,1%–78,7%), în timp ce regiunile din sud și est au cele mai mici valori. Șomajul educațional e scăzut în centrul Europei (sub 5,6%) și ridicat în Spania, Grecia și sudul Italiei (peste 16,1%). La tinerii NEET, sudul Italiei și Bulgaria depășesc media UE cu mai mult de două abateri standard. Nu e o problemă de moment, ci un semn de excludere structurală.

3. Analiza autocorelației spațiale

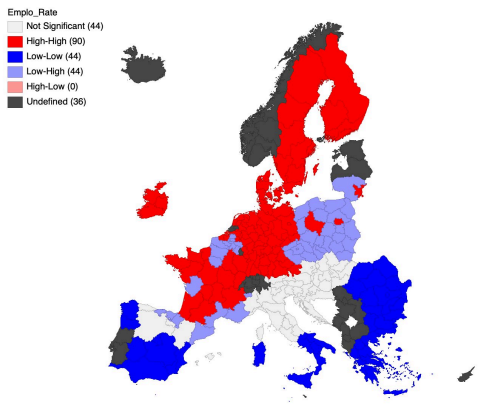
Pentru a măsura cât de mult seamănă o regiune cu vecinii ei, am construit o matrice de vecinătate de tip distance band, pe baza distanței euclidiene dintre centroizi. Pragul de 1.335.937 m e distanța minimă la care fiecare regiune are cel puțin un vecin. Toate testele au folosit 999 de permutări și pragul de semnificație de 0,05 (Anselin, 1995).

3.1. Moran's I global și LISA univariat



Indicele Moran's I are valoarea 0,172 și e semnificativ ($p < 0,05$). Asta înseamnă că regiunile cu ocupare ridicată tind să fie vecine cu regiuni asemănătoare, iar cele cu ocupare scăzută la fel. Un model OLS clasic, care tratează regiunile ca observații independente, nu ar surprinde această legătură. De aici nevoia de modele spațiale.

Fig. 4. Diagrama Moran pentru rata ocupării



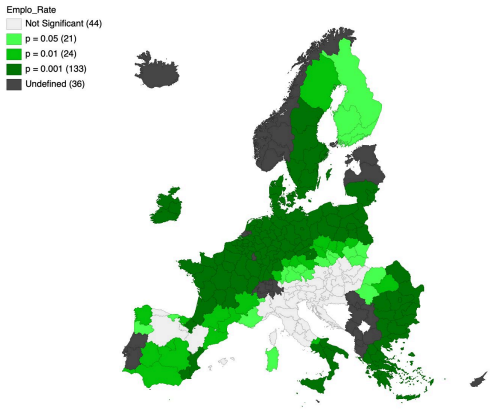
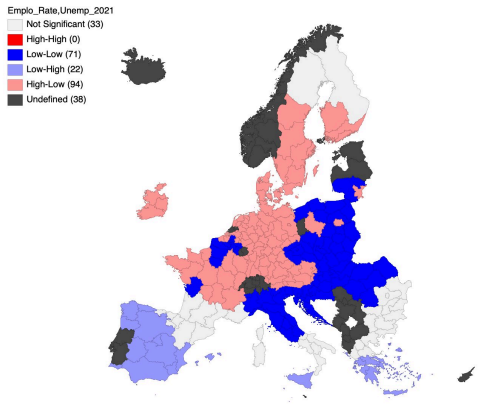


Fig. 5. Harta clusterelor LISA Fig. 6. Harta de semnificație LISA

Harta LISA arată unde anume apar aceste grupări. Clusterul High-High cuprinde 90 de regiuni din Olanda, Germania, Austria și Scandinavia, iar clusterul Low-Low 44 de regiuni din Grecia, Bulgaria, sudul Italiei și Spania. Alte 44 de regiuni sunt de tip Low-High, adică au ocupare scăzută, dar vecini cu ocupare ridicată, și se află mai ales la granița dintre Est și Vest. Rezultatul e solid: 133 de regiuni sunt semnificative la p = 0,001 și formează nucleele clusterelor, 24 la p = 0,01 și 21 la p = 0,05. Doar 44 de regiuni, mai ales din centrul Europei, nu sunt semnificative.

3.2. Autocorelația bivariată locală



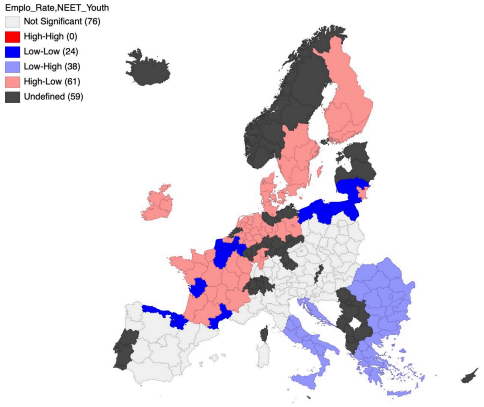


Fig. 7. LISA bivariat: ocupare și șomaj educațional Fig. 8. LISA bivariat: ocupare și NEET

Am vrut să văd și dacă ocuparea dintr-o regiune are legătură cu șomajul și cu NEET din regiunile vecine. În ambele cazuri relația e inversă. Regiunile cu șomaj educațional ridicat tind să fie vecine cu regiuni cu ocupare scăzută. Există totuși și clustere High-Low, zone cu ocupare bună aflate lângă regiuni cu șomaj mare, unde probabil contează mobilitatea forței de muncă peste graniță. La NEET, cele 61 de regiuni High-Low din nord-vestul UE au ocupare ridicată, dar vecini cu mulți tineri NEET. Cele 24 de regiuni Low-Low sunt zone în care ocuparea scăzută și excluderea tinerilor se suprapun (Elhorst, 2014), iar cele 38 de regiuni Low-High se află în sudul Italiei, Grecia și Bulgaria.

4. Modele de regresie spațială

4.1. Modelul OLS

$$Y = 53{,}85 - 1{,}125 \cdot \text{Unemp_2021} - 1{,}331 \cdot \text{NEET_Youth} + \varepsilon$$

Modelul OLS are $R^2 = 0{,}433$ și $F = 74{,}31$ ($p < 0{,}001$), iar ambii predictori sunt semnificativi ($p < 0{,}001$). Diagnosticele arată însă două probleme. Testul Breusch-Pagan ($p = 0{,}001$) indică heteroscedasticitate, iar testul Moran's I pe reziduuri ($p = 0{,}002$) arată că în reziduuri a rămas autocorelație spațială. Modelul explică o parte din variație, dar lasă componenta spațială nemodelată, deci nu e adecvat.

4.2. Selecția modelului spațial

Pentru alegerea modelului am urmat regula Anselin-Florax. Testele Robust LM din modelul OLS indicau inițial un model SEM, pentru că Robust LM-error ($p = 0{,}00017$) e mai semnificativ decât Robust LM-lag ($p = 0{,}00094$). Când am comparat însă modelele estimate, SLM a ieșit mai

bine pe toate criteriile: AIC mai mic (1523,51 față de 1532,98), log-verosimilitate mai mare (−757,75 față de −763,49) și R^2 mai mare (0,490 față de 0,460). Am dat prioritate criteriilor de informație, așa că am ales SLM.

Criteriu	OLS	SLM	SEM
R^2	0,4325	0,4897	0,4596
Log-verosimilitate	−767,14	−757,75	−763,49
AIC	1540,28	1523,51	1532,98
Schwarz	1550,14	1536,66	1542,84
Coeficient spațial	–	ρ = 0,821***	λ = 0,832***

Tabelul 2. Comparația modelelor OLS, SLM și SEM (*** p < 0,001)

4.3. Interpretarea modelului Spatial Lag

Variabilă	Coef.	Std. Err.	z	Prob.
W_Emplo_Rate	0,8210	0,1132	7,250	0,00000
CONSTANT	22,1884	4,5671	4,858	0,00000
Unemp_2021	−0,7948	0,1954	−4,068	0,00005
NEET_Youth	−1,0878	0,1712	−6,353	0,00000

Tabelul 3. Rezultatele modelului SLM (n = 198). Breusch-Pagan = 18,13 (p = 0,00012), LR = 18,77 (p < 0,00001)

Cel mai important rezultat e coeficientul ρ = 0,821 (p < 0,001). Ocuparea unei regiuni depinde puternic de ocuparea din regiunile vecine, ceea ce indică un efect de spillover pe piața muncii. La o creștere cu 1 pp a șomajului educațional, ocuparea scade cu aproximativ 0,80 pp, ceteris paribus. Ponderea tinerilor NEET are cel mai puternic efect (β = −1,088). Testul Breusch-Pagan rămâne semnificativ și în acest model, ceea ce sugerează diferențe structurale între Estul și Vestul Europei pe care modelul nu le acoperă complet.

5. Concluzii

Rata ocupării în regiunile NUTS 2 din UE are o autocorelație spațială pozitivă și semnificativă (I = 0,172, p < 0,05), cu clustere High-High în nord-vestul Europei și Low-Low în sud și est. Modelul SLM arată că ocuparea unei regiuni depinde de trei lucruri: structura educațională a șomajului (β = −0,795), excluderea tinerilor NEET (β = −1,088) și ocuparea din regiunile vecine (ρ = 0,821).

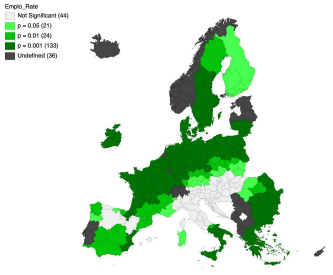
Autocorelația spațială din reziduurile OLS face ca modelul clasic să nu fie suficient, iar trecerea la un model spațial devine necesară. Concret, o creștere cu 1 pp a ocupării în regiunile vecine se asociază cu o creștere de 0,82 pp în regiunea proprie. Din punct de vedere practic, rezultatele susțin politici de coeziune coordonate între regiuni și țări, nu aplicate separat de fiecare stat. Pentru că NEET e cel mai puternic predictor, programe precum Youth Guarantee ar avea un efect mai mare dacă ar fi aplicate coordonat în regiunile vecine.

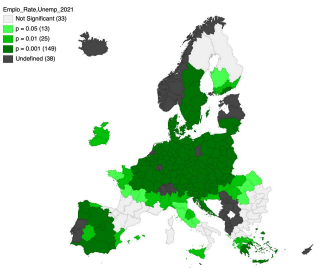
Bibliografie

1. Anselin, L. (1988). *Spatial Econometrics: Methods and Models*. Kluwer Academic Publishers.
2. Anselin, L. (1995). Local Indicators of Spatial Association – LISA. *Geographical Analysis*, 27(2), 93–115.
3. Anselin, L., Syabri, I., Kho, Y. (2006). GeoDa: An Introduction to Spatial Data Analysis. *Geographical Analysis*, 38(1), 5–22.
4. Elhorst, J. P. (2014). *Spatial Econometrics: From Cross-Sectional Data to Spatial Panels*. Springer.
5. LeSage, J., Pace, R. K. (2009). *Introduction to Spatial Econometrics*. CRC Press.
6. Eurostat. Employment rates by NUTS 2 region (lfst_r_lfe2emprt).
7. Eurostat. Unemployment rates by educational attainment level and NUTS 2 region (edat_lfse_04).
8. Eurostat. Young people neither in employment nor in education and training by NUTS 2 region (edat_lfse_20).

Anexă

A1. Hărți de semnificație LISA





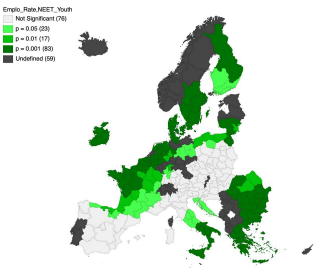


Fig. A1. Rata ocupării Fig. A2. Ocupare și șomaj educațional Fig. A3. Ocupare și NEET

A2. Modelul OLS

Variabilă	Coef.	Std. Err.	t	Prob.
CONSTANT	53,8518	2,0157	26,716	0,00000
Unemp_2021	−1,1249	0,2049	−5,491	0,00000
NEET_Youth	−1,3309	0,1800	−7,394	0,00000

R^2 = 0,4325; R^2 ajustat = 0,4267; F = 74,31 (p < 0,001); AIC = 1540,28; Log-L = −767,14. Jarque-Bera = 3,00 (p = 0,223); Breusch-Pagan = 13,93 (p = 0,001); Koenker-Bassett = 16,49 (p < 0,001). Moran's I (eroare) = −0,022 (p = 0,002); LM-lag = 1,67 (p = 0,196); Robust LM-lag = 10,95 (p = 0,001); LM-error = 4,82 (p = 0,028); Robust LM-error = 14,10 (p = 0,000); SARMA = 15,77 (p < 0,001).

A3. Modelul Spatial Error

Variabilă	Coef.	Std. Err.	z	Prob.
CONSTANT	49,2436	5,4019	9,116	0,00000
Unemp_2021	−0,9172	0,2235	−4,104	0,00004
NEET_Youth	−1,1129	0,1886	−5,901	0,00000
LAMBDA	0,8315	0,1150	7,233	0,00000

R^2 = 0,4596; Log-L = −763,489; AIC = 1532,98; Schwarz = 1542,84. Breusch-Pagan = 21,42 (p = 0,000); LR = 7,30 (p = 0,007).